

[Inscribirse](#)[Iniciar sesión](#)

Medio de búsqueda



Escribir



Publicado en Hacia la ciencia de datos

Esta es su **última** historia gratuita solo para miembros este mes.
[Regístrese en Medium y obtenga uno adicional](#)



Songhao-Wu

[Seguir](#)23 de mayo de 2020 · 5 minutos de lectura · ★ Solo miembros[Escuchar](#)

3 ¿Mejores métricas para evaluar el modelo de regresión?


R cuadrado, R cuadrado ajustado, MSE, RMSE, MAE



342



7



Fuente: foto de Issac Smith en Splash

La evaluación del modelo es muy importante en la ciencia de datos. Le ayuda a comprender el rendimiento de su modelo y facilita la presentación de su modelo a otras personas. Existen muchas métricas de evaluación diferentes, pero solo algunas de ellas son adecuadas para su uso en la regresión. Este artículo cubrirá las diferentes métricas para el modelo de regresión y la diferencia entre ellas. Con suerte, después de leer esta

publicación, tendrá claro qué métricas aplicar a su futuro modelo de regresión.

Cada vez que les digo a mis amigos: "Oye, he creado un modelo de aprendizaje automático para predecir XXX". Su primera reacción sería: "Genial, entonces, ¿cuál es la precisión de la predicción de su modelo?" Bueno, a diferencia de la clasificación, la precisión en un modelo de regresión es un poco más difícil de ilustrar. Es imposible para usted predecir el valor exacto, sino qué tan cerca está su predicción del valor real .

Hay 3 métricas principales para la evaluación del modelo en regresión:

1. *R cuadrado/R cuadrado ajustado*
2. *Error cuadrático medio (MSE)/Error cuadrático medio raíz (RMSE)*
3. *Error absoluto medio (MAE)*

R cuadrado/R cuadrado ajustado

R Square mide cuánta variabilidad en la variable dependiente puede ser explicada por el modelo. Es el cuadrado del Coeficiente de Correlación(R) y por eso se llama R Cuadrado.

$$R^2 = 1 - \frac{SS_{Regression}}{SS_{Total}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Fórmula cuadrada R

R Square is calculated by the sum of squared of prediction error divided by the total sum of the square which replaces the calculated prediction with mean. R Square value is between 0 to 1 and a bigger value indicates a better fit between prediction and actual value.

R Square is a good measure to determine how well the model fits the dependent variables. **However, it does not take into consideration of overfitting problem.** If your regression model has many independent variables, because the model is too complicated, it may fit very well to the training data but performs badly for testing data. That is why Adjusted R Square is introduced because it will penalize additional independent variables added to the model and adjust the metric to prevent overfitting issues.

```
#Example on R_Square and Adjusted R Square  
import statsmodels.api as sm
```

```
X_addC = sm.add_constant(X)
result = sm.OLS(Y, X_addC).fit()
print(result.rsquared, result.rsquared_adj)
# 0.79180307318 0.790545085707
```

In Python, you can calculate R Square using Statsmodel or Sklearn Package

From the sample model, we can interpret that around 79% of dependent variability can be explained by the model, and adjusted R Square is roughly the same as R Square meaning the model is quite robust.

Mean Square Error(MSE)/Root Mean Square Error(RMSE)

While R Square is a relative measure of how well the model fits dependent variables, Mean Square Error is an absolute measure of the goodness for the fit.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Mean Square Error formula

MSE is calculated by the sum of square of prediction error which is real output minus predicted output and then divide by the number of data points. It gives you an absolute number on how much your predicted results deviate from the actual number. You cannot interpret many insights from one single result but it gives you a real number to compare against other model results and help you select the best regression model.

Root Mean Square Error(RMSE) is the square root of MSE. It is used more commonly than MSE because firstly sometimes MSE value can be too big to compare easily. Secondly, MSE is calculated by the square of error, and thus square root brings it back to the same level of prediction error and makes it easier for interpretation.

```
from sklearn.metrics import mean_squared_error
import math
print(mean_squared_error(Y_test, Y_predicted))
print(math.sqrt(mean_squared_error(Y_test, Y_predicted)))
# MSE: 2017904593.23
# RMSE: 44921.092965684235
```

MSE can be calculated in Python using Sklearn Package

Mean Absolute Error(MAE)

Mean Absolute Error(MAE) is similar to Mean Square Error(MSE). However, instead of the sum of square of error in MSE, MAE is taking the sum of the absolute value of error.

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

Mean Absolute Error formula

Compare to MSE or RMSE, MAE is a more direct representation of sum of error terms. **MSE gives larger penalization to big prediction error by square it while MAE treats all errors the same.**

```
from sklearn.metrics import mean_absolute_error
print(mean_absolute_error(Y_test, Y_predicted))
#MAE: 26745.1109986
```

MAE can be calculated in Python using Sklearn Package

Overall Recommendation/Conclusion

R Square/Adjusted R Square is better used to explain the model to other people because you can explain the number as a percentage of the output variability. MSE, RMSE, or MAE are better be used to compare performance between different regression models. Personally, I would prefer using RMSE and I think Kaggle also uses it to assess the submission. However, it makes total sense to use MSE if the value is not too big and MAE if you do not want to penalize large prediction errors.

El cuadrado R ajustado es la única métrica aquí que considera el problema de sobreajuste. R Square tiene una biblioteca directa en Python para calcular, pero no encontré una biblioteca directa para calcular el cuadrado R ajustado, excepto usando los resultados del modelo estadístico. Si realmente desea calcular el R cuadrado ajustado, puede usar statsmodel o usar su fórmula matemática directamente.

¿Le interesa ver las principales métricas para evaluar el modelo de clasificación? Consulte el siguiente enlace:

Las 5 métricas principales para evaluar el modelo de clasificación

A diferencia del modelo de regresión, cuando evaluamos los resultados del modelo de clasificación, no solo debemos centrarnos...



medio.com



Aprendizaje automático

Python de aprendizaje automático

Regresión

Métrica


Ciencia de los datos

Regístrate en La Variable

Por Hacia la ciencia de datos

Every Thursday, the Variable delivers the very best of Towards Data Science: from hands-on tutorials and cutting-edge research to original features you don't want to miss. [Take a look.](#)

By signing up, you will create a Medium account if you don't already have one. Review our [Privacy Policy](#) for more information about our privacy practices.

 Get this newsletter



[About](#) [Help](#) [Terms](#) [Privacy](#)